

第一章 引论

冯 洋

南京大学计算机学院

fengyang@nju.edu.cn

课程简介

- 课程目的
 - 理解程序如何从源代码变为可执行代码；
 - 理解编译器/解释器的设计、实现与测试；
 - 理解编译器/解释器对源代码的优化；
 - 知道编译器是怎么看待你们写的代码的，它会对你们的代码做啥
- 上课时间与地点
 - 周二 5-7节 1-16周 教120
- Office Hours
 - 计算机学院楼313（仙林校区）
 - 早上9到晚上10点一般都在，来之前发个邮件或者QQ说一下就行

课程简介

• 教材

主要教材：《编译方法、技术与实践》，许畅，冯洋等（请大家多提意见。。。）

参考教材：《编译原理》第二版（中文版）-- 机械工业出版社

Aho, Alfred V., Monica S. Lam, Ravi Sethi, and Jeffrey D. Ullman. Compilers: principles, techniques and tools. 2020.

参考教材：现代编译原理（C语言描述）--人民邮电出版社

Appel, Andrew W. Modern compiler implementation in C. Cambridge university press, 2004.

评价形式

平时作业 (0 分): 每周一次, 自愿完成, 自愿提交

课程实验 (60 分): 5~6次实验+ 1 次选做实验(附加 5 分)

期末测试 (40 分): 两小时; 开卷

考勤(0分): 非必要不点名

课程简介

■ 课程网站（建设中）

■ 平时作业

负责助教，一共4位：

尹熙喆：1263522794，email：xizheyin@smail.nju.edu.cn

陈润涛：1517158051，email：211220018@smail.nju.edu.cn

何天行：976792132，email：602022320002@smail.nju.edu.cn

夏天钰：2080871176，email：502025330055@smail.nju.edu.cn

课程群：1084126989

非常重要，请大家务必加群！

非常重要，请大家务必加群！

非常重要，请大家务必加群！

课程简介


• 提问时间？

提纲

- 编译器的结构
- 编译过程
- 语言特征

什么是编译器


- 一个编译器就是一个程序，读入以某一种语言（源语言）编写的程序，并把该程序翻译成为一个等价的、用另一种语言（目标语言）编写的程序。




- 如果翻译过程发现源程序有错，则报错
- 狭义：程序设计语言 → 机器代码
- 广义：程序变换 C++ → C → 汇编 Pascal → C

编译器简介

- 编译器 vs. 解释器
- 编译器的结构
- 编译的构造工具



编译器简介



(Since 1962; 计划 7 卷)


Donald E. Knuth (1938 ~)
Turing Award, 1974

编译器简介




“For his major contributions to *the analysis of algorithms* and *the design of programming languages*, and in particular for his contributions to “*The Art of Computer Programming*” through his well-known books in a continuous series by this title.”
— Turing Award, 1974

编译器



- 效率高，一次编译，多次运行。
- 通常目标程序是可执行的。


解释器



- 直接利用用户提供的输入，执行源程序中指定的操作。
- 不生成目标程序，而是根据源程序的语义直接运行。
- 边解释，边执行，错误诊断效果好。

编译器 vs. 解释器

- Java结合了两者的：
 - 先编译成字节码，再由Java虚拟机解释执行
 - 即时编译**（Just-in-time compiling）




编译器简介

- 编译器 vs. 解释器
- **编译器的结构**
- 编译的构造工具

典型语言（如C）的编译

- 预处理器
- 编译器
- 汇编器
- 链接器
- 加载器



编译器的结构

- 分析部分（Analysis）
 - 源程序 - 语法结构 - 中间表示
 - 搜集源程序中的相关信息，放入符号表
 - 分析、定位程序中可能存在的错误信息（语法、语义错误）
 - 又称编译器的前端（front end），是与机器无关的部分
- 综合部分（Synthesis）
 - 根据符号表和中间表示构造目标程序
 - 又称编译器的后端（back end），是与机器相关的部分

编译器中的若干步骤

- 每个步骤把源程序的一种表示方式转换成另一种表示方式。
- 实践中，某些中间表示不需要明确的构造出来。
- 符号表可由各个步骤使用




符号表管理

- 记录源程序中使用的变量的名字，收集各种属性
 - 名字的存储分配
 - 类型
 - 作用域
 - 过程名字的参数数量、参数类型等等
- 符号表可由编译器的各个步骤使用

类比：英语的分析理解过程

- 词法分析：This line is a longer sentence.
- 语法分析：




语义分析

- This line is a longer sentence.


语法分析

- 词法分析后，需要得到词素序列的语法结构
- 语法分析/解析（syntax analysis/parsing）
 - 根据各个词法单元的第二个分量来创建树形中间表示形式。通常是语法树（syntax tree）。
 - 指出了词法单元流的语法结构。



中间代码生成

- 根据语义分析的输出，生成类机器语言的中间表示
- 三地址代码：
 - 每个指令最多包含三个运算分量
 - t1 = inttfloat(60); t2 = id3 * t1; t3 = id2 + t2;




词法分析

- 词法分析/扫描（lexical analysis, scanning）
 - 读入源程序的字符流，输出有意义的词素(lexeme)
 - 基于词素，产生词法单元：
<token-name, attribute-value>
 - token-name由语法分析步骤使用
 - attribute-value指向相应的符号表条目，由语义分析/代码生成步骤使用
- 例子
 - position = initial + rate * 60
 - <id, 1> <=, > <id, 2> <+, > <id, 3> <*, > <number, 4>


语义分析

- 得到语义(meaning)，对于编译器来说比较难
- 语义分析（semantic analysis）
 - 使用语法树和符号表中的信息，检查源程序是否满足语言定义的语义约束。
 - 同时收集类型信息，用于代码生成。
 - 类型检查，类型转换。




代码优化

- 通过对中间代码的分析，改进中间代码，得到更好的目标代码
 - 快、短、能耗低
- 优化有具体的设计目标



代码生成

- 把中间表示形式映射到目标语言
 - 寄存器的分配
 - 指令选择
 - 内存分配



编译器简介

- 编译器 vs. 解释器
- 编译器的结构
- 编译的构造工具

编译技术的应用

- 高级程序设计语言的实现
 - 高级程序设计语言的抽象层次的提高有利于编程，但是直接生成的代码却相对低效率
 - 聚合类型/高级控制流/面向对象/垃圾自动收集机制
- 针对计算机体系结构的优化
 - 并行性：指令级并行，处理器层次并行
 - 内存层次结构
- 新体系结构的设计
 - RISC
 - 专用体系结构
 - 一个新的体系结构特征能否被充分利用，取决于编译技术

编译器的趟 (Pass)


- 趟：以文件为输入输出单位的编译过程的个数，每趟可由一个或若干个步骤构成
- “步骤”是逻辑组织方式
- “趟”和具体的实现相关
 - 参考LLVM实现中的Pass

编译器的构造工具

- 语法分析器的生成器： yacc/bison
 - 根据一个程序设计语言的语法描述自动生成语法分析器
- 扫描器的生成器: lex/flex
 - 根据一个语言的词法单元的正则表达式描述生成词法分析器
- 语法制导的翻译引擎
 - 生成一组用于遍历分析树并生成中间代码的程序
- 代码生成器的生成器
 - 把中间语言的每个运算翻译成目标机上机器语言的规则，生成代码生成器
- 数据流分析引擎
 - 收集数据流信息，用于优化
- 编译器构造工具集

编译技术的应用

- 程序翻译
 - 二进制翻译/硬件合成/数据查询解释器/编译后模拟
- 软件生产率工具
 - 类型检查
 - 边界检查
 - 内存管理工具



- 语言的代分类
 - 第一代语言：机器语言
 - 第二代语言：汇编语言
 - 第三代语言：高级程序设计语言
 - Fortran, Pascal, Lisp, Modula, C
 - 第四代：特定应用语言：NOMAD, SQL, Postscript
 - 第五代：基于逻辑和约束的语言，Prolog、OPS5

- 命令式语言/声明式语言
 - 前者指明如何完成，后者指明要完成哪些计算
- 冯·诺依曼语言/面向对象的语言/脚本语言
- 面向对象语言
 - Simula, Smalltalk, Modula3, C++, Object Pascal, Java, C#
 - 数据抽象、继承

- 程序设计语言的新发展向编译器设计者提出新要求
 - 设计相应的算法和表示方法来翻译和支持新的语言特征
- 通过降低高级语言的执行开销，推动这些高级语言的使用
- 编译器设计者还需要更好地利用新硬件的能力

- 静态/动态
 - 静态：语言策略支持编译器静态决定某个问题
 - 动态：只允许在程序运行时刻作出决定
 - Java类声明中的static指明了变量的存放位置可静态确定
- 作用域
 - x的一个声明的作用域是指程序中的一个区域，其中对x的使用都指向这个声明
 - 静态作用域：通过静态阅读程序决定作用域
 - 动态作用域


- 环境与状态
 - 环境：是从名字到存储位置的映射
 - 状态：从内存位置到它们的值的映射
- 环境的改变需要遵守语言的作用于规则

```
...
int i;                /* 全局 i */
...
void f(...) {
    int i;            /* 局部 i */
    ...
    i = 3;            /* 对局部 i 的使用 */
    ...
}
...
x = i + 1;            /* 对全局 i 的使用 */
```



- 静态作用域和块结构
 - C族语言使用静态作用域。
 - C语言程序由顶层的变量、函数声明组成
 - 函数内部可以声明变量（局部变量/参数），这些声明的作用域在它出现的函数内
 - 一个顶层声明的作用域包括其后的所有程序。除去那些具有同样名字的变量声明的函数体。
 - 作用域规则基于程序结构，声明的作用域由它在程序中的位置隐含决定。
 - 也通过public、private、protected进行明确控制

- 块作用域实例



声 明	作用域
int a=1;	$B_1 - B_3$
int b=1;	$B_1 - B_2$
int b=2;	$B_2 - B_4$
int a=3;	B_3
int b=4;	B_4

- 动态作用域
 - 对一个名字x的使用指向的是最近被调用但还没有终止且声明了x的过程中的这个声明。

```
#include<stdio.h>  
#define a (x+1)  
  
int x = 2;  
void c(){ printf("%d\n",a);}   
void b(){ int x=1; printf("%d\n",a);}   
  
int main(){  
    b();  
    c();  
}
```

```
#include<stdio.h>  
#define a (x+1)  
  
int x = 2;  
void c(){ printf("%d\n",a);}   
void b(){ int x=1; printf("%d\n",a); c();}   
  
int main(){  
    b();  
}
```

- 参数传递机制
 - 值调用 (call by value): 对实在参数求值/拷贝，再存放到被调用过程的形参的内存位置上
 - 引用调用(call by reference): 实际传递的是实在参数的地址
 - 名调用: 早期使用，现在已经基本废弃

- 别名:
 - 两个指针指向同一个位置的情况
 - 导致看起来不同的形式参数实际上是对方的别名