

18、数据仓库设计的三级数据模型

概念模型、逻辑模型、物理模型

1. 概念模型

概念模型是为一定目标设计系统、收集信息而服务的概念型工具，是客观世界到机器世界的中间层次。PPT 中提到可以使用 E-R 法表示概念模型。

概念模型设计主要做三件事：

内容	说明
确定系统边界	明确要支持哪些决策、决策者关心什么问题、需要什么信息、涉及哪些数据源
确定主要主题及其内容	明确数据仓库的分析对象，即主题
OLAP 等分析应用设计	明确后续要支持哪些分析操作

确定主题时，需要描述主题及其属性信息、属性取值情况、主题公共码键、主题之间的关系，之后可以用 E-R 模型表示概念数据模型。

例子：

商品、顾客、供应商可以作为主题。商品主题可以包含商品固有信息、采购信息、销售信息、库存信息等。

2. 逻辑模型

逻辑模型描述数据仓库主题的逻辑实现，PPT 中对应的是关系模型。

逻辑模型设计主要包括：

内容	说明
E-R 图转换为关系表	把概念模型转换成二维表
定义数据源和抽取规则	明确每个属性来自哪个源系统、源表、源字段
粒度划分	确定数据是细节数据、轻度总结还是高度总结
数据分割	把逻辑整体数据分割成较小、可独立管理的数据单元
定义合适的数据来源	确保数据可获得、可集成、可分析

粒度划分会直接影响数据仓库的数据量和能够回答的查询类型，是影响数据仓库性能的重要因素。

3. 物理模型

物理模型是逻辑模型在数据仓库中的实现。PPT 中说，物理模型设计是在逻辑模型基础上确定数据的存储结构、索引策略、存储分配、数据存放位置等物理内容，目的是提高数据仓库访问性能。

常用技术包括：

技术	作用
合并表	减少多表连接的 I/O 开销
建立数据序列	提高顺序访问效率
引入冗余	减少分析时需要访问的表数量
表的物理分割	提高管理和查询性能
生成导出数据	预先生成常用分析数据
建立广义索引	加快查询
规范化 / 反规范化	在存储与查询性能之间权衡

数据仓库设计的三级数据模型包括概念模型、逻辑模型和物理模型。概念模型是客观世界到机器世界的中间层次，用于确定系统边界、主要主题及分析应用，常用 E-R 法表示；逻辑模型描述数据仓库主题的逻辑实现，通常把 E-R 图转换为关系表，并定义数据源、抽取规则、粒度和数据分割策略；物理模型是逻辑模型在数据仓库中的具体实现，关注存储结构、索引策略、存储分配和物理优化，其目的是提高数据仓库访问性能。