

19、数据挖掘的方法

定义：对数据库或数据仓库中蕴涵的、未知的、非平凡的、有潜在应用价值的模式或规则的提取

方法	作用
特征规则挖掘	描述一类数据对象的普遍特征
关联规则挖掘	发现事务数据中项与项之间的关联关系
序列模式分析	发现数据对象之间的先后时序关系
分类分析	根据训练样本建立模型，对未知数据分类
聚类分析	对没有类别标记的数据自动划分群组

1. 特征规则挖掘

是一种常见的知识形式，它用于描述一类数据对象的普遍特征，是普化知识的一种
特征规则的数据挖掘方法有两类：

1. 面向属性归约方法

它通过属性值之间的概念层次结构进行归约，获得概括性知识。例如，把“南京”提升为“江苏”，再把“江苏”提升为“华东”，这叫概念提升。概念提升的目的包括规范化属性取值，提高模式的置信度和兴趣度。

2. 数据立方方法

数据立方方法利用预先计算好的统计、求和等综合结果进行挖掘，可以减少重复统计查询，提高挖掘效率。它和 OLAP 中的上卷、下钻思想有关。

特征规则挖掘用于描述一类对象的普遍特征，属于普化知识发现。其主要方法包括面向属性归约方法和数据立方方法。面向属性归约通过概念层次树对属性值进行概念提升，以获得概括性知识。

2. 关联规则挖掘

关联规则挖掘用于发现事务数据库中多个属性或项之间的关联程度。

典型形式是：

$A \rightarrow B$

含义是：出现 A 的事务中，经常也出现 B。

例如：

购买尿布 → 购买啤酒

购买面包和黄油 → 购买牛奶

关联规则挖掘用于发现事务数据中项与项之间的关联关系，规则形式为 $A \rightarrow B$ 。其核心指标是支持度和置信度，满足最小支持度和最小置信度的规则称为强规则。Apriori 算法利用“频繁项集的任一子集必定频繁”的性质寻找频繁项集。

3. 序列模式分析

序列模式分析与关联规则类似，也是为了找出数据对象之间的联系，但它更强调前后时序关系。也就是说，它不仅关心“哪些项经常一起出现”，还关心“哪些事件先发生、哪些事件后发生”。

例如：

下雨 → 洪涝

购买电筒 → 购买电池

序列模式分析用于发现具有时间先后关系的数据对象之间的联系。它与关联规则挖掘类似，但更强调事件之间的前因后果和时序关系。

4. 分类分析

分类分析是数据挖掘的重要方法之一。分类分析通过分析训练数据样本，产生关于类别的精确描述，并用于对未来数据进行分类和预测。

1. 基本思想

分类分析需要先有已经标记类别的数据。例如：

信用等级：优、良、一般、差；

是否购买电脑：yes / no；

客户是否流失：流失 / 未流失。

系统先根据这些带类别标记的数据学习规则，再对未知类别的数据进行预测。

2. 分类分析的两个步骤

步骤	内容
建立模型	用训练数据集构造分类模型
使用模型分类	评估模型准确性，并对未知类别数据分类

因为训练样本已经给出了类标号，所以分类分析属于有指导学习。

3. 常见分类方法

包括：

决策树方法

贝叶斯方法

人工神经网络方法

约略集方法

遗传算法

其中，决策树是一种树结构：内部结点表示属性测试，边表示测试结果，叶结点表示类别或类别分布。

分类分析是一种有指导学习方法。它先利用带有类标号的训练数据建立分类模型，再用该模型对未知类别的数据进行分类和预测。常见方法包括决策树、贝叶斯、人工神经网络、约略集和遗传算法。

5. 聚类分析

聚类分析又称集群分析。它和分类分析相反：分类分析的数据已经有类别标记，而聚类分析面对的是没有类别标记的记录。系统按照距离或相似性等规则自动划分记录集合，相当于自动给数据打标签。

聚类分析可以分为距离聚类和相似系数聚类，主要方法包括：

划分方法

层次方法

基于密度的方法

基于网格的方法

基于模型的方法

聚类分析的结果可以表现为聚类树

聚类分析是一种无指导学习方法，输入数据没有预先给定类别标记，系统根据距离或相似性自动把记录划分为若干簇。主要方法包括划分方法、层次方法、基于密度的方法、基于网格的方法和基于模型的方法。

总结：常用的数据挖掘方法包括特征规则挖掘、关联规则挖掘、序列模式分析、分类分析和聚类分析等。特征规则挖掘用于描述一类数据对象的普遍特征，常用方法有面向属性归纳方法和数据立方方法；关联规则挖掘用于发现事务数据中项与项之间的关联关系，规则形式为 $A \rightarrow B$ ，核心指标是支持度和置信度；序列模式分析用于发现数据对象之间的前后时序关系；分类分析是一种有指导学习方法，通过带类标号的训练数据建立模型，并对未知类别数据进行分类和预测；聚类分析是一种无指导学习方法，对没有类别标记的数据按照距离或相似性自动划分为若干簇。此外，数据挖掘还包括异常分析、时序数据挖掘等方法。